

Data Science

CC3084



Excelencia que trasciende

DELVALLE
GRUPO EDUCATIVO

Laboratorio 2 - Deep Learning

Daniela Ramírez de León, 23053

José Pablo Donado López, 22684

Cindy Mishelle Gualim Pérez, 21226

GUATEMALA, 2 de agosto de 2026

1. Introducción

Este informe corresponde a la segunda fase del análisis del ingreso de viajeros internacionales a Guatemala, y utiliza las mismas series y particiones construidas en el Laboratorio 1. El trabajo tiene dos objetivos: evaluar si un modelo de red neuronal recurrente (LSTM) mejora los pronósticos obtenidos antes con modelos estadísticos clásicos, y explorar la similitud entre las siete series mediante el algoritmo catch22. Todo el código y los resultados intermedios están en el notebook Laboratorio2.ipynb del repositorio del grupo.

2. Ejercicio 1: modelos LSTM

2.1 Datos y preparación

Se trabajó con dos de las siete series del laboratorio anterior: **Total** y **Vía Aérea**. Se conservó el mismo corte cronológico 70/30, con entrenamiento de 2009-01 a 2021-03 ($N = 147$) y prueba de 2021-04 a 2026-06 ($N = 63$). Los valores se escalaron al rango $[0, 1]$ con MinMaxScaler ajustado únicamente sobre el entrenamiento, para no filtrar información del conjunto de prueba. Luego se construyeron ventanas deslizantes de 12 meses para predecir el mes siguiente, lo que produce 135 ventanas de entrenamiento y 51 de prueba por serie.

2.2 Configuración de los modelos y tuneo de parámetros

Ambos modelos comparten la misma arquitectura base —una capa LSTM seguida de una capa densa de salida—, optimizador Adam con tasa de aprendizaje 0.001, función de pérdida MSE y lotes de 8 observaciones. El tuneo se realizó sobre dos parámetros: el número de unidades ocultas y la cantidad de épocas de entrenamiento.

- **Modelo 1:** 32 unidades ocultas, 50 épocas.
- **Modelo 2:** 64 unidades ocultas, 100 épocas.

En las cuatro corridas (dos modelos por dos series) la curva de pérdida desciende de forma sostenida y se estabiliza antes de terminar el entrenamiento, sin señales de divergencia, lo que indica que la cantidad de épocas fue suficiente en ambas configuraciones.

2.3 Resultados y selección del mejor modelo

La evaluación se hizo sobre el conjunto de prueba, en la escala original de la serie. El criterio principal de selección fue el **RMSE**, por penalizar con más fuerza los errores grandes, y se complementó con MAE y MAPE para confirmar que la conclusión no dependiera de la métrica elegida.

Modelo	Serie	RMSE	MAE	MAPE
LSTM 1	Total	63,824.1	49,021.7	15.87 %
LSTM 2	Total	58,218.3	45,795.1	15.15 %
LSTM 1	Vía Aérea	18,349.1	15,175.5	16.14 %
LSTM 2	Vía Aérea	17,382.6	12,745.8	13.60 %

El **Modelo 2 resultó mejor en ambas series y en las tres métricas**, por lo que fue el seleccionado para predecir. En la serie Total reduce el RMSE un 8.8 % respecto al Modelo 1; en Vía Aérea la mejora es de

5.3 % en RMSE y de 2.5 puntos porcentuales en MAPE. Que el modelo más grande y entrenado por más tiempo gane en ambos casos sugiere que la configuración inicial se quedaba corta en capacidad y que, con 100 épocas, todavía no se llega a sobreajustar.




Figura 1. Serie Total: predicciones de ambos modelos frente a los valores reales.




Figura 2. Serie Vía Aérea: predicciones de ambos modelos frente a los valores reales.

En las dos series el Modelo 2 sigue el nivel y el ritmo de la recuperación pos-pandemia con bastante fidelidad. El error remanente se concentra en los picos estacionales, que ambos modelos tienden a suavizar.

2.4 Comparación con los modelos del Laboratorio 1

Modelo	Serie	RMSE	MAE	MAPE
Holt-Winters	Total	168,288.8	148,782.5	48.80 %
LSTM 1	Total	63,824.1	49,021.7	15.87 %
LSTM 2	Total	58,218.3	45,795.1	15.15 %
Holt-Winters	Vía Aérea	29,846.3	24,619.3	24.30 %
LSTM 1	Vía Aérea	18,349.1	15,175.5	16.14 %
LSTM 2	Vía Aérea	17,382.6	12,745.8	13.60 %

Los dos modelos LSTM superan al mejor modelo clásico en ambas series y en las tres métricas. En la serie Total, el Modelo 2 reduce el RMSE un 65.4 % frente a Holt-Winters y baja el MAPE de 48.8 % a 15.1 %; en Vía Aérea la reducción de RMSE es de 41.8 % y el MAPE cae de 24.3 % a 13.6 %.

La diferencia se explica por el período de prueba. Holt-Winters extrapola la tendencia y la estacionalidad aprendidas antes de 2021 y no puede representar la recuperación pos-pandemia, por lo que arrastra un sesgo sistemático a lo largo de todo el horizonte. El LSTM, en cambio, predice a partir de los últimos 12 meses observados, de modo que se reajusta al nuevo nivel de la serie conforme avanza. Conviene señalar que en el Laboratorio 1 la única forma de acercarse a este desempeño fue incorporar manualmente una variable de intervención COVID (SARIMA(1,1,2)(0,1,1)₁₂ + COVID, RMSE = 75,299.6 en la serie Total); el Modelo 2 obtiene un error 22.7 % menor que ese modelo sin necesitar información externa sobre la pandemia.

3. Ejercicio 2: análisis de similitud con catch22

3.1 Idea detrás de catch22

catch22 es una versión reducida de **hctsa** (*Highly Comparative Time-Series Analysis*), una metodología que describe una serie de tiempo calculando miles de métricas estadísticas —autocorrelación, entropía, no linealidad, forma de la distribución—. Ese enfoque es muy costoso computacionalmente y buena parte de las métricas resultan redundantes entre sí.

catch22 (Fulcher, Little & Jones, 2013) selecciona **22 características representativas** que conservan gran parte de la capacidad de discriminación del conjunto completo, eliminando la redundancia y reduciendo drásticamente el tiempo de cálculo. Su importancia está en que permite comparar y clasificar series de tiempo de forma estandarizada y automática, sin depender de conocimiento previo del dominio: cada serie queda resumida en un vector de 22 números que puede tratarse como cualquier conjunto de variables.

3.2 Extracción de características y construcción de la matriz

Se extrajeron las 22 características con la librería pycatch22 para las siete series de entrenamiento construidas en el Laboratorio 1: Total, Vía Aérea, Vía Terrestre, Vía Marítima, Región América del Centro, Región América del Norte y Región Europa. El resultado es una **matriz de 7×22** , donde cada fila es una serie y cada columna una característica. Como las características tienen escalas muy distintas entre sí, se estandarizaron por columna (z-score) antes de cualquier análisis comparativo.

3.3 Análisis exploratorio de la matriz

Sobre la matriz estandarizada se aplicaron cinco técnicas: análisis de componentes principales, clustering jerárquico (Ward), mapa de calor de las características, matriz de correlaciones entre características y mapa de distancias euclidianas entre series. Los dos primeros componentes principales explican el **74.5 % de la varianza** (52.5 % y 22.0 %), de modo que el plano PC1-PC2 resume bien la estructura del conjunto.




Figura 3. Proyección de las siete series sobre los dos primeros componentes principales.




Figura 4. Clustering jerárquico (Ward) de las siete series según catch22.




Figura 5. Mapa de calor de las 22 características estandarizadas.




Figura 6. Matriz de correlaciones entre las características de catch22.




Figura 7. Mapa de distancias euclidianas entre series en el espacio catch22.

3.4 Series con comportamientos más similares

Las series **Total**, **Vía Terrestre** y **Región América del Centro** son las más parecidas entre sí. En el dendrograma son las primeras en unirse y registran las distancias más bajas de toda la matriz (Total–Región Centro = 3.48; Total–Vía Terrestre = 4.16); en el PCA ocupan la misma zona, con valores muy

negativos de PC1. **Vía Aérea** se incorpora después al mismo grupo, con una distancia mayor (6.01 respecto a Vía Terrestre), lo que indica una similitud menor.

El resultado es consistente con la composición del conjunto de datos: según el Laboratorio 1, cerca del 73 % de los viajeros proviene de Centroamérica y alrededor del 60 % ingresa por vía terrestre, de modo que esas tres series describen en gran medida el mismo flujo desde perspectivas distintas. Lo relevante es que *catch22* identifica esa relación únicamente a partir de propiedades estadísticas, sin usar información sobre el origen de los viajeros.

3.5 Características más discriminantes

El **primer componente principal** (52.5 % de la varianza) está dominado por *forecast_error*, *acf_timescale*, *centroid_freq*, *ami2*, *entropy_pairs* y *transition_matrix*, es decir, por características que describen la **capacidad de predicción** y la **estructura de autocorrelación** de cada serie, no su magnitud ni su nivel.

El **segundo componente** (22.0 % adicional) responde principalmente a *dfa*, *mode_10*, *mode_5* y *outlier_timing_pos/neg*, que reflejan el comportamiento de las fluctuaciones de largo plazo y la presencia y ubicación de valores atípicos. Entre ambos resumen casi tres cuartas partes de la información contenida en las siete series.

3.6 Grupos naturales y agrupamiento por categoría

El dendrograma muestra **dos grupos claros**:

- **Grupo A — flujo principal y comportamiento estable:** Total, Vía Terrestre, Región América del Centro y, con similitud algo menor, Vía Aérea. Presentan *forecast_error* bajo (0.60 a 0.69) y patrones de tendencia y estacionalidad bien definidos, más fáciles de modelar.
- **Grupo B — turismo de larga distancia y mayor variabilidad:** Vía Marítima, Región América del Norte y Región Europa. Tienen *forecast_error* más alto (0.80 a 1.04), mayor presencia de valores atípicos y un comportamiento de largo plazo menos estable.

Las series de una misma categoría **se agrupan solo parcialmente**. Entre las regiones, Norte y Europa sí forman un par cercano (distancia 5.58, la segunda más baja de la matriz): aunque geográficamente no tienen relación, ambas representan turismo de larga distancia y sufrieron una caída cercana al 100 % durante la pandemia. Región Centro, en cambio, se asocia con Total y Vía Terrestre. En las vías de ingreso no hay agrupamiento por categoría: Vía Terrestre queda en el Grupo A, Vía Marítima en el Grupo B y Vía Aérea en una posición intermedia. Pesa más el tipo de turismo que representa cada serie que el medio de ingreso en sí.

3.7 Serie con el comportamiento más atípico

Vía Marítima es, por un margen amplio, la serie más atípica. Su distancia promedio al resto es de **8.75**, muy por encima de la siguiente (Región América del Norte, 7.28), e incluye la distancia máxima de toda la matriz (10.19 frente a Región América del Centro). En el dendrograma permanece aislada hasta una altura de 8.45 y en el PCA es el punto extremo en ambos componentes.

Las características que explican esa separación son: *acf_timescale* = 1.49 frente a 4.0–8.9 en el resto (autocorrelación que decae casi de inmediato, muy poca memoria); *forecast_error* = 1.04, el más alto de

las siete series; *low_freq_power* = 0.54, casi el doble de la siguiente, junto con el *centroid_freq* más bajo (0.64), lo que indica energía concentrada en oscilaciones lentas e irregulares en lugar de un ciclo anual estable; *outlier_timing_neg* = -0.015, mientras las otras seis series rondan 0.88; y *stretch_high* = 9 frente a 42 en el Grupo A.

Hay tres razones concretas detrás de este comportamiento. Primero, la serie **termina en 2020-03 (N = 135)** y no en 2021-03 como las demás, por lo que **no contiene el colapso de la pandemia**; eso explica directamente el valor de *outlier_timing_neg*. Segundo, es la serie con mayor estacionalidad (0.712), menor tendencia (0.195) y mayor volatilidad (CV = 0.781) del laboratorio anterior: un perfil de oscilación estacional sin nivel de referencia estable. Tercero, **cambia de composición tres veces** durante el período (Crucevistas + Turista hasta 2016, luego solo Crucevistas), lo que introduce quiebres artificiales que catch22 registra como baja memoria y alto error de pronóstico. En el Laboratorio 1 esta serie ya se había señalado como poco confiable de forma cualitativa; aquí el diagnóstico queda cuantificado sin recurrir a información del dominio.

3.8 Comparación con el análisis exploratorio tradicional

Los agrupamientos de catch22 **son consistentes** con el análisis exploratorio del Laboratorio 1, aunque no se construyen sobre los mismos criterios.

- **Tendencia — consistente.** El Grupo A reúne las series con mayor fuerza de tendencia STL (Vía Aérea 0.791, Total 0.789, Región Centro 0.747, Vía Terrestre 0.684), mientras que Vía Marítima, con la tendencia más baja (0.195), queda fuera de todo grupo. Por esta vía, en cambio, la separación entre Norte (0.595) y Europa (0.713) es menos nítida.
- **Estacionalidad — parcialmente consistente.** Las series de mayor estacionalidad (Marítima 0.712, Europa 0.600, Aérea 0.575) caen en el Grupo B o en posiciones intermedias, y las de menor estacionalidad (Terrestre 0.126, Centro 0.221) en el Grupo A. Sin embargo, catch22 no separa por esta dimensión: *periodicity* detecta un período de 11 meses en Total, Aérea, Marítima y Europa, y de 3 en Terrestre, Centro y Norte, división que no coincide con los clusters.
- **Volatilidad — consistente.** Vía Marítima era la serie más volátil (CV = 0.781) y es también la de mayor *forecast_error* (1.04) y la más aislada del dendrograma.
- **Impacto de la pandemia — consistente.** Es donde la coincidencia es más clara: Norte y Europa, las dos series con caída máxima de 100 %, forman el par más cercano del Grupo B. Además, las seis series que llegan hasta 2021-03 comparten *outlier_timing_neg* $\approx$ 0.88, es decir, sus valores extremos se concentran al final del período; Vía Marítima, cuya ventana termina antes, es la única excepción.
- **Autocorrelación — consistente.** *acf_timescale* reproduce el orden esperado: Terrestre 8.86, Centro 8.69 y Total 8.32 (memoria larga, Grupo A) frente a Norte 5.10, Europa 4.01 y Marítima 1.49 (Grupo B). Esto concuerda con que todas las series requirieran diferenciación y con que Europa fuera la única que necesitó $d = 2$. La excepción es *acf_first_min*, que vale 3 en Vía Terrestre pese a que esta pertenece al Grupo A.

En resumen, catch22 llega a una estructura compatible con la del análisis tradicional, pero organizada alrededor de la **predictibilidad y la estructura de autocorrelación** más que de la tendencia y la estacionalidad, que fueron los ejes del laboratorio anterior.

3.9 Descubrimientos no evidentes en el análisis tradicional

- **Total, Vía Terrestre y Región América del Centro son casi la misma serie en términos estadísticos.** Sus distancias mutuas (3.48, 3.51 y 4.16) son las tres menores de la matriz. En el Laboratorio 1 se modelaron por separado y las tres terminaron con la misma especificación SARIMA(1,1,2)(0,1,1)₁₂; catch22 muestra que esa coincidencia no era casual, sino redundancia. Modelar una y derivar las otras por proporción sería una simplificación razonable.
- **Región América del Norte y Región Europa se comportan igual pese a no tener relación geográfica.** Sus perfiles STL son distintos (estacionalidad 0.469 frente a 0.600; tendencia 0.595 frente a 0.713) y el análisis tradicional no daba motivo para asociarlas. catch22 las une mediante características que no se habían revisado: son las dos únicas series con *outlier_timing_pos* por debajo de 0.5 (0.401 y 0.497) y comparten un *transition_matrix* bajo (0.026 y 0.030).
- **catch22 localiza el quiebre de la pandemia sin que se le indique dónde buscarlo.** En el Laboratorio 1 hubo que construir manualmente una variable dummy de COVID, apoyada en conocimiento del contexto. La característica *outlier_timing_neg* señala el mismo fenómeno de forma automática: vale ≈ 0.88 en las seis series que incluyen 2020-2021 y -0.015 en la única que no lo hace. Una sola característica identifica tanto la existencia del quiebre como su ubicación temporal.
- **La dificultad de pronóstico puede estimarse antes de ajustar ningún modelo.** *forecast_error* ordena las series de más a menos predecible (Centro 0.600, Terrestre 0.613, Total 0.616, Aérea 0.692, Europa 0.803, Norte 0.855, Marítima 1.042) y reproduce los extremos observados en el Laboratorio 1. La correspondencia no es exacta en las posiciones intermedias —Vía Terrestre tiene *forecast_error* bajo pero un MAPE alto (60.9 %)— porque esta característica se calcula sobre el entrenamiento, mientras que el MAPE se evalúa sobre la recuperación pos-pandemia, que no está representada en él.

3.10 Modelo LSTM con las características de catch22

Se construyó un tercer modelo para la serie Total con la misma arquitectura base del Modelo 2 (64 unidades ocultas, 100 épocas), concatenando el vector de 22 características estandarizadas de la serie con la salida de la LSTM antes de la capa densa final. Como esas características son estáticas —describen la serie completa, no cada ventana— se repiten en todas las observaciones.

Modelo	Serie	RMSE	MAE	MAPE
LSTM 2 (sin catch22)	Total	58,218.3	45,795.1	15.15 %
LSTM + catch22	Total	78,478.7	59,574.6	18.51 %




Figura 8. Serie Total: modelo con características catch22 frente al Modelo 2.

El modelo con características catch22 **no mejoró** al mejor modelo del Ejercicio 1: el RMSE sube un 35 % y el MAPE pasa de 15.1 % a 18.5 %.

El resultado es esperable por la forma en que entra la información. Como la red se entrena sobre una sola serie, las 22 características toman **el mismo valor en las 135 ventanas de entrenamiento**. Al ser constantes, no aportan ninguna señal que permita distinguir una ventana de otra y en la práctica funcionan como un sesgo adicional; lo que sí agregan son 22 entradas y una capa densa intermedia, es decir, más parámetros que ajustar con la misma cantidad de datos. El efecto neto es mayor capacidad sin información nueva, lo que favorece el sobreajuste. A esto se suma que los modelos 1 y 2 se entrenaron sin fijar semilla, por lo que parte del margen corresponde a variabilidad entre corridas; aun así, la dirección del resultado es clara.

Estas características sí resultarían útiles en un esquema **multiserie**: si la red se entrenara con las siete series a la vez, el vector catch22 dejaría de ser constante y le permitiría identificar con qué tipo de serie está trabajando —memoria larga o corta, estable o volátil— y ajustar su comportamiento en consecuencia. Ese es el uso natural de catch22 como entrada de un modelo y queda como la extensión pendiente del ejercicio.

4. Conclusiones

- El Modelo 2 (64 unidades ocultas, 100 épocas) fue el mejor en ambas series y en las tres métricas evaluadas, por lo que el tuneo de capacidad y épocas sí tuvo efecto.
- Los modelos LSTM superan claramente a los del Laboratorio 1: 65.4 % menos RMSE que Holt-Winters en la serie Total y 41.8 % menos en Vía Aérea. La ventaja proviene de que el LSTM predice a partir de la ventana más reciente y se adapta a la recuperación pos-pandemia, mientras que los modelos clásicos extrapolan un patrón previo al quiebre.
- catch22 separa las siete series en dos grupos: el flujo principal centroamericano y terrestre, estable y predecible, y el turismo de larga distancia, más volátil. Los agrupamientos son consistentes con el análisis exploratorio anterior, pero se organizan alrededor de la predictibilidad y la autocorrelación, no de la tendencia ni la estacionalidad.

- Vía Marítima es la serie más atípica del conjunto, y catch22 permite atribuirlo a causas concretas: ventana más corta que no incluye la pandemia, muy poca memoria y cambios de composición durante el período.
- El principal aporte del análisis con catch22 es diagnóstico, no predictivo: revela redundancia entre series, agrupa por comportamiento y localiza quiebres de forma automática. Incorporar sus características a un LSTM entrenado sobre una sola serie no mejora el pronóstico, porque el vector es constante; su utilidad aparecería en un modelo entrenado sobre varias series a la vez.